

Documentación de Dataset

14 de junio de 2026

1. Documentación Técnico-Estructurada del Dataset

El conjunto de datos eco-acústicos provisto para el desarrollo del pipeline se compone de dos particiones tabulares limpias extraídas de registros biológicos reales: `eco_acoustic_train.csv` (1906 observaciones) y `eco_acoustic_test.csv` (477 observaciones). Ambos archivos poseen una estructura homogénea constituida por exactamente 68 columnas, descritas formalmente según su naturaleza analítica a continuación:

1.1. Variables de Identificación y Metadatos

- **recording_id**: Identificador alfanumérico único correspondiente al archivo original de audio del cual se extrajo la muestra. Esta variable actúa como clave primaria para la indexación y la simulación interactiva orientada al despliegue en la consola web de Streamlit.
- **songtype_id**: Variable categórica codificada que registra el tipo específico de manifestación acústica o canto emitido por el espécimen biológico.
- **is_tp**: Indicador binario técnico de validación (*True Positive*), el cual parametriza la fiabilidad y certeza de la presencia de la señal acústica dentro de la ventana temporal capturada.
- **species_id**: Variable objetivo de tipo discreto (*Label*) que identifica numéricamente la especie faunística detectada en el registro. El dataset de entrenamiento se encuentra acotado a exactamente 5 clases objetivo distribuidas de forma asimétrica, parametrizando los IDs: 10, 12, 17, 18 y 23.

1.2. Características del espacio de características (64 Columnas)

- **mel_0 a mel_63**: Conjunto de características numéricas continuas que constituyen el espacio de variables predictoras ($X \in \mathbb{R}^{64}$). Estas colum-

nas representan los coeficientes de energía condensados de la escala Mel-Frequency Cepstral Coefficients (MFCC), calculados a través del preprocesamiento de la señal de audio digital. Estas variables capturan las propiedades físicas fundamentales de la frecuencia y el timbre del sonido, sirviendo como los descriptores matemáticos puros requeridos para alimentar de forma directa tanto las transformaciones geométricas no supervisadas como los modelos de clasificación.

1.3. Catálogo e Identificación Taxonómica de las Clases Objetivo

species_id	Nombre Científico	Tipo de Fauna
10	<i>Leptodactylus discodactylus</i>	Anfibio
12	<i>Osteocephalus taurinus</i>	Anfibio
17	<i>Chiroxiphia lineata</i>	Ave
18	<i>Saltator grossus</i>	Ave
23	<i>Pheucticus chrysopheplus</i>	Ave

Cuadro 1: Clasificación taxonómica de las clases objetivo del dataset.